

Ficha del modelo: predicción de abandono Telco

Versión: 2.0
Fecha de corte: 23 de septiembre de 2026
Responsable de revisión: Gael Andrés García García
Estado: Prototipo validado para uso analítico supervisado; no aprobado para decisiones automáticas en producción.

Identificación

Campo	Descripción
Nombre	Telco Churn Retention Model
Versión	1.0
Tipo	Clasificación binaria con probabilidades estimadas para la toma de decisiones por umbral
Modelo final	Random Forest con ingeniería de características integrada en el pipeline
Artefacto	telco_model_final.joblib
Metadatos	telco_model_metadata.json
Semilla	42

Propósito

Estimar la probabilidad de que un cliente abandone un servicio de suscripción y priorizar acciones preventivas de retención. La salida debe interpretarse como una señal de riesgo, no como una afirmación de que el cliente abandonara.

Usuarios previstos

- Analistas de datos y responsables de retención.
- Personal de servicio al cliente con capacitación para interpretar probabilidades.
- Responsables de negocio que definan campanas y costos de intervención.
- Equipo técnico encargado de ejecutar, monitorear y actualizar el artefacto.

Usos permitidos

- Priorizar llamadas, encuestas o revisiones de servicio.
- Comparar escenarios de umbral y capacidad operativa.
- Analizar patrones agregados de abandono.
- Apoyar el diseño de campanas de retención con supervisión humana.

Usos no recomendados

- Cancelar, negar o modificar automáticamente un servicio.
- Cambiar precios o condiciones contractuales de forma automática.
- Tomar decisiones disciplinarias o de elegibilidad.
- Interpretar las variables importantes como causas del abandono.
- Usar la predicción fuera de la población representada por el dataset sin una nueva validación.

Dataset y variable objetivo

- **Dataset:** Telco Customer Churn, archivo Telco-Customer-Churn.csv.
- **Tamaño:** 7,043 registros y 21 variables originales.
- **Objetivo:** Churn.
- **Clase positiva:** Yes, codificada como 1.
- **Distribución:** 73.5% No y 26.5% Yes aproximadamente.
- **Identificador excluido:** customerID.
- **Versión de scikit-learn:** 1.9.0.

Preprocesamiento e ingeniería

- TotalCharges se convierte a numérico; los espacios vacíos se tratan como faltantes.
- Variables numéricas: imputación por mediana y estandarización.
- Variables categóricas: imputación por moda y One-Hot Encoding.
- Variables derivadas: has_internet, num_services, contract_short_term, new_customer, monthly_to_tenure_ratio, total_over_tenure y paperless_electronic_check.
- El preprocesamiento vive dentro del pipeline para evitar fuga de información.

Métricas y resultados

La partición fue 70% entrenamiento, 15% validación y 15% prueba, con estratificación.

Validación del modelo final

- Accuracy: 0.763
- Precisión: 0.539
- Recall: 0.736
- F1-score: 0.622
- ROC-AUC: 0.836

Prueba final con umbral 0.40

- Accuracy: 0.743
- Precisión: 0.510
- Recall: 0.804
- F1-score: 0.624
- ROC-AUC: 0.836

Matriz de confusión en prueba: TN=559, FP=217, FN=55, TP=226. La curva ROC obtuvo AUC=0.836 y la curva precision-recall obtuvo AP aproximado de 0.66.

El umbral 0.40 prioriza la detección de clientes en riesgo y debe revisarse contra costos reales de falsos positivos y falsos negativos.

Limitaciones

- El dataset es histórico y puede no representar el comportamiento actual.
- No se dispone de una variable temporal suficiente para una validación prospectiva.
- El resultado depende de la calidad y disponibilidad de los datos de entrada.

- El modelo no demuestra causalidad.
- La evaluación de sesgo por subgrupos requiere un análisis adicional y criterios de equidad definidos por la organización.
- La selección de características no redujo el número de variables transformadas en esta ejecución: se conservaron 52 de 52.
- Las probabilidades de Random Forest no deben interpretarse como probabilidades perfectamente calibradas; se requiere una prueba de calibración antes de uso operativo.

Riesgos

- **Falsos negativos:** no contactar a un cliente que abandona.
- **Falsos positivos:** usar recursos en clientes que permanecerían.
- **Deriva de datos:** cambios en tarifas, contratos o comportamiento.
- **Sesgo histórico:** reproducir desigualdades presentes en los datos.
- **Automatización indebida:** convertir una probabilidad en una decisión sin revisión.
- **Fuga operativa:** utilizar datos que no estén disponibles al momento de inferencia.

Análisis de sesgos

La notebook incluye variables demográficas y de servicio, pero no presenta una auditoria completa de desempeño por grupo. Antes de desplegar el modelo se deben comparar precisión, recall, F1 y tasas de falsos positivos y negativos por género, edad aproximada, tipo de contrato, método de pago y otros grupos relevantes. Si aparecen diferencias importantes, la organización debe documentarlas, investigar su origen y definir límites aceptables antes de utilizar el modelo.

Las variables importantes globales fueron, entre otras, `monthly_to_tenure_ratio`, `contract_short_term`, `TotalCharges`, `tenure`, contrato mensual, `total_over_tenure`, `MonthlyCharges`, ausencia de seguridad en línea y ausencia de soporte técnico. Estas importancias indican asociación predictiva, no causalidad.

Mecanismo de inferencia

1. Recibir un registro con las columnas predictoras originales esperadas.
2. Validar que existan las columnas requeridas y que los tipos sean compatibles.
3. Aplicar el pipeline serializado, incluyendo imputación, escalamiento y codificación.
4. Obtener `predict_proba` para la clase positiva.
5. Clasificar como cliente de riesgo si la probabilidad es mayor o igual que 0.40.
6. Enviar la señal a un flujo de retención con revisión humana.

El artefacto contiene el pipeline completo y el umbral. La inferencia debe realizarse con la misma ingeniería de características usada durante el entrenamiento.

El archivo `inferencia_telco.py` recibe registros raw, valida la estructura, aplica el pipeline serializado y devuelve probabilidad, clasificación, umbral, versión y obligación de revisión humana. No debe cargarse un archivo Joblib/Pickle de una fuente desconocida, porque la deserialización puede ejecutar código arbitrario.

Plan de monitoreo

- Revisar mensualmente la distribución de las variables de entrada y la proporción de predicciones positivas.

- Comparar trimestralmente precisión, recall, F1 y ROC-AUC cuando ya se conozca el resultado real.
- Monitorear la tasa de faltantes, categorías nuevas y cambios en la disponibilidad de columnas.
- Revisar el desempeño por subgrupos y los conteos de falsos positivos y falsos negativos.
- Registrar cada ejecución, versión del artefacto, fecha, umbral y conjunto de datos utilizado.
- Alertar si faltantes superan 1%, aparecen categorías nuevas en más de 1% de los registros o el tiempo de inferencia por registro supera 100 ms.
- Comparar mensualmente distribuciones de variables; investigar un PSI mayor que 0.20 y suspender si supera 0.30 junto con deterioro de métricas.

Criterios de actualización

Actualizar o reentrenar el modelo cuando ocurra cualquiera de estas condiciones: - ROC-AUC o F1 disminuyan más de 10% respecto a la línea base validada. - Recall de la clase positiva quede por debajo del mínimo acordado por el negocio. - Aparezcan cambios persistentes en la distribución de variables o en la tasa de abandono. - Se incorporen nuevos servicios, tarifas, contratos o métodos de pago. - Se detecten diferencias de desempeño o riesgos de equidad no aceptables. - El periodo de datos utilizado deje de representar la operación vigente. - F1 o ROC-AUC disminuyan más de 10% frente a la línea base, o el recall quede por debajo de 0.70 durante dos periodos consecutivos. - Suspender el uso si faltan columnas críticas, se detectan valores imposibles o las diferencias de FNR/FPR entre grupos resultan operativamente inaceptables.

Toda actualización debe repetir la validación, actualizar esta ficha, generar nuevos metadatos y conservar el artefacto anterior para trazabilidad.