

Informe técnico final

Predicción de abandono de clientes Telco

Estudiante: Gael Andrés García García

Materia: Algoritmos de Aprendizaje Automático

Fecha: 23 de septiembre de 2026

Versión del informe: 2.0

Portada

Proyecto final: Predicción de abandono de clientes

Dataset: Telco Customer Churn

Modelo final: Random Forest con pipeline completo y umbral operativo 0.40

Artefacto: telco_model_final.joblib

1. Resumen ejecutivo

El proyecto construye un flujo reproducible para identificar clientes con mayor probabilidad de abandonar un servicio de suscripción. Se parte del avance inicial y se incorporan ingeniería de características, preprocesamiento dentro de pipelines, validación cruzada, comparación de modelos, ajuste de hiperparámetros, selección de características, optimización del umbral, interpretabilidad y serialización.

El modelo final es Random Forest. En validación obtuvo F1-score de 0.622, recall de 0.736 y ROC-AUC de 0.836. En el conjunto de prueba, con umbral 0.40, alcanzo accuracy de 0.743, precisión de 0.510, recall de 0.804, F1-score de 0.624 y ROC-AUC de 0.836. El resultado es adecuado como herramienta de priorización, pero no como decisión automática.

2. Descripción del problema

La variable Churn indica si un cliente abandono el servicio. La clase positiva es Yes, codificada como 1. El objetivo es estimar el riesgo de abandono para apoyar acciones de retención. Se trata de un problema de clasificación binaria con clases desbalanceadas: aproximadamente 26.5% de los clientes abandonan y 73.5% permanecen.

La solución responde a la pregunta: **¿cómo utilizar datos históricos del cliente para priorizar de forma responsable las acciones de retención?**

3. Evolución desde el avance de proyecto

El avance inicial permitía cargar y explorar el dataset, realizar un preprocesamiento básico y comparar modelos iniciales. La versión final amplía ese trabajo con:

- Variables derivadas orientadas al problema de retención.
 - Partición estratificada en entrenamiento, validación y prueba.
 - Pipelines que contienen todas las transformaciones.
 - Validación cruzada estratificada.
 - Comparación de DummyClassifier, regresión logística, árbol, Random Forest y SVC calibrado.
 - Ajuste acotado de Random Forest y SVC.
 - Selección de características mediante regularización L1.
 - Evaluación de varios umbrales.
 - Análisis de importancia de variables y errores.
 - Serialización del pipeline y sus metadatos.
 - Ficha del modelo y reporte ejecutivo.
-

4. Dataset y variable objetivo

Elemento	Valor
Nombre	Telco Customer Churn
Archivo	Telco-Customer-Churn.csv
Observaciones	7,043
Variables originales	21
Objetivo	Churn
Clase positiva	Yes = 1
Identificador excluido	customerID
Fuente declarada	BlastChar, Kaggle

La distribución aproximada es 73.5% de clientes que permanecen y 26.5% de clientes que abandonan. Este desbalance justifica no depender exclusivamente de accuracy.

5. Calidad y preprocesamiento

TotalCharges se recibe con tipo texto y contiene espacios vacíos. Se convierte a numérico y los valores vacíos se transforman en faltantes. Los faltantes numéricos se imputan con la mediana y los categóricos con la moda.

Las variables numéricas se estandarizan con StandardScaler. Las variables categóricas se transforman con OneHotEncoder(handle_unknown='ignore'). customerID se excluye porque funciona como identificador y podría favorecer sobreajuste sin aportar un patrón generalizable.

Todas estas transformaciones están dentro de un ColumnTransformer y un Pipeline, por lo que los parámetros se ajustan solo con los datos de entrenamiento de cada partición. Esto reduce el riesgo de fuga de información.

6. Ingeniería de características

Se agregaron las siguientes variables:

- `has_internet`: indica si el cliente cuenta con internet.
- `num_services`: número de servicios contratados entre teléfono, seguridad, respaldo, protección, soporte y streaming.
- `contract_short_term`: identifica contratos mensuales.
- `new_customer`: identifica clientes con hasta 12 meses de antigüedad.
- `monthly_to_tenure_ratio`: relación entre cargo mensual y antigüedad.
- `total_over_tenure`: cargos acumulados relativos a la antigüedad.
- `paperless_electronic_check`: combinación de facturación sin papel y pago por cheque electrónico.

Estas variables buscan representar antigüedad, vinculación con servicios, modalidad contractual y presión relativa de cargos. Son variables predictivas, no explicaciones causales.

7. Estrategia de validación

Se utilizó una partición estratificada:

Partición	Proporción	Registros aproximados
Entrenamiento	70%	4,930
Validación	15%	1,056
Prueba	15%	1,057

La validación cruzada utiliza cinco particiones estratificadas sobre entrenamiento. El conjunto de prueba se mantiene separado hasta la evaluación final. La semilla utilizada es 42.

8. Modelos comparados

Modelo	Función
DummyClassifier	Baseline que predice la clase mayoritaria
LogisticRegression	Línea base interpretable
DecisionTree	Modelo no lineal de baja complejidad
RandomForest	Modelo ensamblado para capturar relaciones no lineales
SVC calibrado	Clasificador de margen con probabilidades calibradas

Se utilizó `CalibratedClassifierCV` para el SVC en lugar de `probability=True`, evitando una opción deprecated en la versión actual de scikit-learn.

9. Ajuste de hiperparametros

Se uso GridSearchCV con F1-score y validación cruzada estratificada. El espacio se mantuvo acotado para que el experimento fuera reproducible y computacionalmente viable.

Random Forest exploro 200 y 300 árboles, profundidad sin límite, hojas mínimas de 1 y 3 y peso de clases balanceado. SVC exploro kernel RBF y valores de C 1.0, 2.0 y 5.0, con calibración sigmoid y tres particiones internas.

Los mejores resultados fueron:

- Random Forest: n_estimators=300, min_samples_leaf=3, class_weight='balanced', F1 cruzado = 0.631.
- SVC calibrado: C=1.0, kernel RBF, class weight balanceado, F1 cruzado = 0.608.

10. Selección y reducción de características

Se utilizo SelectFromModel con regresión logística y regularización L1. En scikit-learn 1.9 se expresa esta configuración con l1_ratio=1.0 y solver='liblinear'.

La selección con umbral mediano conservo 52 de 52 variables transformadas. El modelo reducido y el modelo completo obtuvieron las mismas métricas de validación en esta ejecución. Por tanto, no se justifica eliminar variables únicamente por esta prueba; se conserva el pipeline completo para mantener la trazabilidad.

11. Registro de experimentos

Experimento	Resultado	Decisión
DummyClassifier	Accuracy aproximada 0.735, recall 0	Se conserva como referencia, no como modelo operativo
Comparación inicial	LogisticRegression obtuvo ROC-AUC 0.850 en validación	Se conserva como baseline interpretable
Validación cruzada	Random Forest tuvo F1 cruzado 0.565 en la comparación inicial	Se ajusta con GridSearchCV
Ajuste Random Forest	F1 cruzado 0.631	Se considera candidato final
Ajuste SVC calibrado	F1 cruzado 0.608	Se conserva como alternativa
Selección L1	52 de 52 variables, sin mejora adicional	Se mantiene el pipeline completo
Umbral 0.40	Aumenta la sensibilidad para detectar abandono	Se fija para la evaluación operativa

12. Evaluación final

Validación

Modelo	Accuracy	Precisión	Recall	F1-score	ROC-AUC
LogisticRegression	0.808	0.665	0.554	0.604	0.850
RandomForest	0.763	0.539	0.736	0.622	0.836
SVC	0.777	0.574	0.625	0.598	0.832

Random Forest se selecciona por obtener el mayor F1-score entre los candidatos finales y un recall de validación superior a la regresión logística.

Prueba con umbral 0.40

Métrica	Resultado
Accuracy	0.743
Precisión	0.510
Recall	0.804
F1-score	0.624
ROC-AUC	0.836

13. Análisis de errores

Un falso negativo es un cliente que abandona y no es identificado. Es el error con mayor riesgo comercial si la finalidad es retener clientes. Un falso positivo es un cliente que se marca para revisión, pero permanece; produce costo operativo o una oferta innecesaria.

El umbral 0.40 prioriza recall. Por ello, se debe asumir que una parte considerable de los clientes contactados no abandonara. Esto no es necesariamente un defecto: puede ser una elección razonable si el costo de perder un cliente supera el costo de una revisión adicional.

14. Optimización del umbral

Se probaron umbrales entre 0.30 y 0.60. En validación, un umbral 0.40 produjo aproximadamente precisión 0.503, recall 0.861 y F1-score 0.635 para el modelo final. En la prueba, el valor produjo recall 0.804 y F1-score 0.624.

La selección final debe revisarse junto con capacidad del equipo, valor esperado de una retención, costo de promociones y costo de falsos negativos. El umbral no debe considerarse universal.

15. Selección del modelo

Random Forest fue seleccionado porque ofrece el mejor equilibrio F1 entre los candidatos ajustados y mantiene un recall elevado. La decisión no se basa solo en accuracy: el baseline demuestra que la clase mayoritaria puede producir una accuracy alta sin detectar abandonos.

La selección es válida para este dataset, esta partición y este contexto. Una selección para producción requeriría validación temporal, análisis de costos y auditoria de subgrupos.

Matriz de decisión ponderada

Modelo	F1 (30%)	Recall (25%)	ROC-AUC (20%)	Interpreta bilidad (10%)	Complejid ad (10%)	Operación (5%)	Total
RandomFo rest	30	25	20	10	10	5	100
SVC	27	20	18	7	7	4	83
LogisticRe gression	25	18	20	10	10	5	88

Random Forest obtiene la mayor puntuación total bajo esta ponderación, que prioriza la detección de abandono y mantiene en cuenta interpretabilidad, complejidad y operación.

16. Interpretabilidad global y local

Las variables con mayor importancia global fueron:

Variable transformada	Importancia aproximada
monthly_to_tenure_ratio	0.129
contract_short_term	0.091
TotalCharges	0.076
tenure	0.071
Contract_Month-to-month	0.070
total_over_tenure	0.065
MonthlyCharges	0.064
OnlineSecurity_No	0.042
TechSupport_No	0.030
Contract_Two year	0.030

La interpretabilidad local se realiza mediante la probabilidad individual, la predicción por umbral y la inspección de casos representativos. Estas explicaciones muestran asociaciones del modelo y no deben presentarse como causas del abandono.

En prueba se revisaron cuatro casos: TP con probabilidad 0.557, contrato mensual y 17 meses; TN con probabilidad 0.291, contrato anual y 43 meses; FP con probabilidad 0.416, contrato mensual, fibra y cargo mensual 89.80; FN con probabilidad 0.117, contrato anual y 45 meses. El FP sugiere revisar el costo de contactos cerca del umbral; el FN muestra que un cliente real puede parecer estable con las variables disponibles.

17. Análisis de sesgos

El dataset contiene variables demográficas y de servicio, pero no se realizó una auditoria completa por grupos. Antes de desplegar el modelo se deben comparar por grupo precisión, recall, F1, tasa de falsos positivos y tasa de falsos negativos.

Los grupos a revisar incluyen género, indicador de adulto mayor, tipo de contrato, método de pago, antigüedad y tipo de servicio de internet. Las diferencias deben investigarse antes de emplear el modelo para campanas que puedan afectar de forma desigual a los clientes.

En prueba, por género: mujeres $n=505$, abandono=0.291, recall=0.769, FPR=0.296 y FNR=0.231; hombres $n=552$, abandono=0.243, recall=0.843, FPR=0.266 y FNR=0.157. Por SeniorCitizen: grupo 0 $n=896$, abandono=0.234, recall=0.776, FPR=0.255 y FNR=0.224; grupo 1 $n=161$, abandono=0.441, recall=0.887, FPR=0.467 y FNR=0.113. Estas diferencias describen el comportamiento observado y requieren contexto; no permiten concluir discriminación por si solas.

18. Riesgos y condiciones de uso

El modelo es un sistema de apoyo. No debe utilizarse para negar servicios, modificar precios, cancelar contratos o tomar decisiones irreversibles sin revisión humana.

Los principales riesgos son la deriva de datos, el sesgo histórico, los falsos negativos, los falsos positivos, el uso de columnas no disponibles durante inferencia y la interpretación causal de importancias. La organización debe definir un responsable, un umbral revisable, una bitácora y un procedimiento de apelación o corrección humana.

19. Serializacion

La notebook guarda un diccionario en `telco_model_final.joblib` con:

- nombre del modelo;
- pipeline completo;
- umbral seleccionado;
- columnas esperadas;
- variable objetivo;
- clase positiva.

También guarda `telco_model_metadata.json` con el nombre del modelo, umbral, métricas de validación, métricas de prueba e importancias principales.

El artefacto 2.0 contiene los pasos ingeniería, preprocesamiento y modelo, junto con versión, fecha, semilla, hiperparametros, tiempos, matriz de confusión y advertencia de seguridad. No debe cargarse un Joblib/Pickle de una fuente desconocida.

20. Mecanismo de inferencia

El mecanismo esperado es:

1. Recibir un registro con las columnas de entrada.
2. Validar nombres, presencia y tipos básicos.
3. Aplicar la misma ingeniería de características.
4. Ejecutar el pipeline serializado.
5. Obtener `predict_proba` para la clase positiva.
6. Comparar la probabilidad con 0.40.
7. Generar una alerta de revisión humana.

La inferencia debe rechazar o poner en cuarentena registros con columnas faltantes, valores imposibles o categorías que no puedan interpretarse. Las categorías nuevas pueden ser ignoradas por el encoder, pero deben registrarse para monitoreo.

El script independiente `inferencia_telco.py` fue probado con un registro válido, un campo faltante, una categoría desconocida, un tipo incorrecto, una columna adicional y un valor extremo. También se simuló cinco perfiles: bajo riesgo, riesgo medio, alto riesgo, categoría poco frecuente y cercano al umbral.

21. Validación de entradas

Antes de inferir se deben comprobar:

- presencia de todas las columnas predictoras requeridas;
- ausencia de la columna objetivo en registros nuevos;
- tipos numéricos válidos para antigüedad y cargos;
- valores no negativos en tenure y cargos;
- categorías conocidas o registro de categorías nuevas;
- ausencia de identificadores duplicados cuando el flujo los requiera;
- trazabilidad de fecha, versión del modelo y fuente del registro.

22. Plan de monitoreo

Frecuencia	Revisión
Mensual	Faltantes, categorías nuevas, rangos, tasa de predicciones positivas y cambios de distribución
Trimestral	Precisión, recall, F1, ROC-AUC y matriz de errores cuando exista etiqueta real
Trimestral	Desempeño por subgrupos y análisis de equidad
Por campana	Tasa real de retención, costo por contacto y beneficio neto

Por versión	Registro de artefacto, metadatos, semilla, dataset y umbral
Mensual	Tiempo de inferencia por registro; alerta si supera 100 ms
Mensual	PSI o cambio de distribución; investigar >0.20 y suspender si >0.30 con deterioro

23. Criterios de actualización

Se debe considerar reentrenamiento si F1 o ROC-AUC disminuyen más de 10% frente a la línea base, si el recall queda por debajo del mínimo acordado, si cambia de forma persistente la tasa de abandono, si aparecen nuevos servicios o tarifas o si se detectan diferencias de equidad no aceptables.

Cada actualización debe conservar el modelo anterior, repetir la validación, actualizar la ficha, guardar nuevos metadatos y documentar el motivo del cambio.

La suspensión inmediata procede si faltan columnas críticas, se detectan valores fuera de rango, el pipeline no puede validar entradas, el recall cae bajo 0.70 durante dos periodos, F1/ROC-AUC disminuyen más de 10% o las diferencias de error por grupo superan el límite institucional.

24. Trazabilidad

Elemento	Registro
Notebook	Proyecto final Telco - Gael Garcia.ipynb
Dataset	Telco-Customer-Churn.csv
Modelo	telco_model_final.joblib
Metadatos	telco_model_metadata.json
Semilla	42
Partición	70/15/15 estratificada
Versión scikit-learn	1.9.0
Versión del modelo	2.0
Fecha de entrenamiento	23 de septiembre de 2026
Script de inferencia	inferencia_telco.py
Dependencias	requirements.txt
Fecha de corte	23 de septiembre de 2026
Responsable	Gael Andrés García García

25. Ficha del modelo

La ficha operativa completa se encuentra en [ficha_modelo_telco.md](#). Incluye propósito, usuarios, usos permitidos y no recomendados, dataset, métricas, umbral, limitaciones, riesgos, sesgos, inferencia, monitoreo, actualización y responsable.

26. Conclusiones personales

La solución evolucionó desde una comparación inicial de modelos hacia un flujo reproducible que conserva la separación entre entrenamiento, validación y prueba. La evidencia principal para seleccionar Random Forest fue su mejor F1 entre los candidatos ajustados y su recall elevado para la clase de abandono.

El resultado final muestra que la selección de umbral es tan importante como la elección del algoritmo. El umbral 0.40 favorece la detección de clientes en riesgo, pero genera una precisión moderada y, por tanto, requiere capacidad operativa y revisión humana.

Las limitaciones que permanecen son la naturaleza histórica del dataset, la falta de validación temporal, la ausencia de un análisis completo de equidad y la falta de una función de costo empresarial formal. También debe comprobarse que todas las variables estén disponibles y actualizadas antes de una inferencia real.

Antes de utilizar el modelo en producción sería necesario validar con datos recientes, calibrar probabilidades, definir costos y criterios de umbral, auditar subgrupos, establecer monitoreo continuo, proteger la trazabilidad y asignar un responsable formal de revisión. Con esas condiciones, el modelo puede servir como apoyo prudente para priorizar acciones de retención, pero no como sustituto de la decisión humana.